



ΠΑΝΕΠΙΣΤΗΜΙΟ ΔΥΤΙΚΗΣ ΑΤΤΙΚΗΣ
ΣΧΟΛΗ ΜΗΧΑΝΙΚΩΝ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ ΠΛΗΡΟΦΟΡΙΚΗΣ

Εργασία εαρινού εξαμήνου ακαδημαϊκού έτους 2025-2026

Big Data and Data Mining Project- IMDB Movie Reviews Dataset

ΟΝΟΜΑΤΕΠΩΝΥΜΑ: Μανιάκη Φωτεινή, Κανάτα Παρασκευή

ΕΞΑΜΗΝΟ: 8ο

A.M.: ice22390133, ice22390074

Github Repository: <https://github.com/Viikanata/bigdata>

Google Collab:

https://colab.research.google.com/drive/19UL3EJF-pXh3aoNyg_D2Nksla74oFwR1#scrollTo=Q9tKzgis6CJ0

Περιεχόμενα

1. Εισαγωγή	3
2. Κατανόηση και Προεπεξεργασία Δεδομένων (Data Preprocessing)	3
2.1 Περιγραφή του Dataset	3
2.2 Καθαρισμός Δεδομένων (Data Cleaning)	4
2.3 NLP Engineering (Stopwords & Lemmatization)	5
2.4 Μηχανική Χαρακτηριστικών (Feature Engineering - TF-IDF)	5
3. Εξερευνητική Ανάλυση Δεδομένων (EDA)	5
3.1 Στατιστική Ανάλυση Κατανομής Κλάσεων	5
3.2 Κατανομή Μήκους Κειμένων	6
3.3 Ανάλυση WordClouds	7
4. Μεθοδολογία & Υλοποίηση Αλγορίθμων	8
4.1 Εποπτευόμενη Μάθηση (Supervised Classification)	8
4.2 K-Means Clustering (Unsupervised Learning)	9
5. Αξιολόγηση και Σύγκριση Μοντέλων	9
5.1 Πίνακας Συγκεντρωτικών Metrics	10
5.2 Ανάλυση Μητρών Σύγχυσης (Confusion Matrices)	11
5.3 Ανάλυση Καμπύλης ROC / AUC	11
5.4 Αιτιολόγηση Ανωτερότητας του SVM	13
6. Συμπεράσματα	13

1. Εισαγωγή

Αντικείμενο της παρούσας εξαμηνιαίας εργασίας είναι η σχεδίαση και η υλοποίηση ενός ολοκληρωμένου (end-to-end) συστήματος ανάλυσης δεδομένων και ταξινόμησης βάσει συναισθήματος (Sentiment Analysis). Χρησιμοποιώντας το dataset IMDB Movie Reviews της Kaggle, το έργο στοχεύει στην ανάπτυξη ενός αγωγού (pipeline) που μπορεί να διαβάζει κριτικές ταινιών, να τις καθαρίζει από περιττά γλωσσικά στοιχεία, να τις μετατρέπει σε αριθμητικές οντότητες και τελικά να προβλέπει με υψηλή ακρίβεια αν μια κριτική είναι θετική ή αρνητική.

2. Κατανόηση και Προεπεξεργασία Δεδομένων (Data Preprocessing)

2.1 Περιγραφή του Dataset

Το σύνολο δεδομένων IMDB Dataset που χρησιμοποιήσαμε αποτελείται από 50.000 αυτόνομες κριτικές ταινιών. Πρόκειται για ένα σύνολο δεδομένων για δυαδική ταξινόμηση συναισθημάτων, το οποίο περιέχει σημαντικά περισσότερα δεδομένα από προηγούμενα σύνολα δεδομένων αναφοράς. Η δομή του είναι απλή καθώς περιλαμβάνει δύο μόνο στήλες:

1. `review` (Τύπος: Object/String): Το πλήρες κείμενο της κριτικής, όπως γράφτηκε από τον χρήστη.
2. `sentiment` (Τύπος: Object/String): Η ετικέτα στόχος με τιμές `positive` ή `negative`.

Κατά τον αρχικό έλεγχο με τη χρήση της εντολής `df.isnull().sum()`, διαπιστώθηκε ότι δεν υπάρχουν ελλειπείς τιμές (missing values) σε καμία από τις δύο στήλες, γεγονός που εξασφαλίζει την ακεραιότητα του δείγματος χωρίς ανάγκη για τεχνικές συμπλήρωσης δεδομένων (imputation).

```
[nltk_data] Downloading package stopwords to /root/nltk_data...
[nltk_data] Package stopwords is already up-to-date!
[nltk_data] Downloading package wordnet to /root/nltk_data...
[nltk_data] Package wordnet is already up-to-date!
True
```

Πρώτες Γραμμές Δεδομένων:

```
review sentiment
0 One of the other reviewers has mentioned that ... positive
1 A wonderful little production. <br /><br />The... positive
2 I thought this was a wonderful way to spend ti... positive
3 Basically there's a family where a little boy ... negative
4 Petter Mattei's "Love in the Time of Money" is... positive
```

Πληροφορίες Dataset:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 50000 entries, 0 to 49999
Data columns (total 2 columns):
#   Column      Non-Null Count  Dtype
---  -
0   review      50000 non-null  object
1   sentiment   50000 non-null  object
dtypes: object(2)
memory usage: 781.4+ KB
None
```

Έλεγχος για Missing Values:

```
review      0
sentiment    0
dtype: int64
```

2.2 Καθαρισμός Δεδομένων (Data Cleaning)

Τα δεδομένα κειμένου από το διαδίκτυο περιέχουν μεγάλο ποσοστό θορύβου που δυσχεραίνει τη σύγκλιση των αλγορίθμων. Η συνάρτηση `clean_text` που αναπτύχθηκε, εκτέλεσε τα εξής βήματα:

- **Μετατροπή σε Πεζά (Lowercase):** Αποτρέπει το μοντέλο από το να θεωρεί την ίδια λέξη ως δύο διαφορετικά χαρακτηριστικά λόγω κεφαλαίων γραμμάτων (π.χ. "Movie" και "movie").
- **Αφαίρεση HTML Tags:** Οι κριτικές του IMDB περιέχουν συχνά tags αλλαγής γραμμής όπως `<br />`. Αυτά αφαιρέθηκαν πλήρως με χρήση Regular Expressions (`re.sub(r'<.*?>', '', text)`).
- **Αφαίρεση Σημείων Στίξης & Αριθμών:** Σημεία όπως θαυμαστικά, τελείες και παύλες απομονώθηκαν και διαγράφηκαν, καθώς δεν προσφέρουν γενικεύσιμη πληροφορία για το συναίσθημα.
- **Αφαίρεση Newlines:** Οι χαρακτήρες αλλαγής γραμμής (`\n`) αντικαταστάθηκαν από κενά διαστήματα.

2.3 NLP Engineering (Stopwords & Lemmatization)

Μετά τον βασικό καθαρισμό, εφαρμόσαμε τεχνικές NLP μέσω της βιβλιοθήκης NLTK:

- **Stopwords Removal:** Λέξεις με υψηλή συχνότητα εμφάνισης που λειτουργούν ως συνδετικοί κρίκοι στη γλώσσα αλλά στερούνται συναισθηματικού βάρους (όπως the, is, at, which, on) φιλτραρίστηκαν και αφαιρέθηκαν.
- **Lemmatization (Λημματοποίηση):** Χρησιμοποιώντας τον WordNetLemmatizer, όλες οι εναλλακτικές μορφές μιας λέξης ανάχθηκαν στη βασική, λεξικογραφική τους ρίζα (π.χ. οι λέξεις running, runs, ran μετατρέπονται όλες στο run, ενώ το characters γίνεται character). Αυτό μειώνει δραματικά τη διασπορά του λεξιλογίου.

2.4 Μηχανική Χαρακτηριστικών (Feature Engineering - TF-IDF)

Οι αλγόριθμοι μηχανικής μάθησης απαιτούν αριθμητικούς πίνακες ως είσοδο. Για τον σκοπό αυτό χρησιμοποιήσαμε τη μέθοδο TF-IDF (Term Frequency - Inverse Document Frequency). Για την αποφυγή του προβλήματος της «κατάρτας της πολυδιαστατικότητας» (Curse of Dimensionality), ορίστηκε η παράμετρος max_features=5000. Με αυτόν τον τρόπο, κρατήσαμε μόνο τις 5.000 λέξεις με το υψηλότερο σκορ TF-IDF σε όλο το corpus, μετατρέποντας το κείμενο σε έναν ελεγχόμενο, αραιό πίνακα (sparse matrix) διαστάσεων 50000 $\times$ 5000\$. Τέλος, οι ετικέτες κλάσης κωδικοποιήθηκαν ψηφιακά (positive $\rightarrow$ 1\$, negative $\rightarrow$ 0\$).


3. Εξερευνητική Ανάλυση Δεδομένων (EDA)

3.1 Στατιστική Ανάλυση Κατανομής Κλάσεων

Όπως προκύπτει από το πρώτο ραβδόγραμμα (Sentiment Distribution), το δείγμα είναι απολύτως ισορροπημένο, καθώς αποτελείται από ακριβώς 25.000 θετικές (positive) και 25.000 αρνητικές (negative) κριτικές.

Σε πολλά προβλήματα ταξινόμησης, η ασυμμετρία των κλάσεων (class imbalance) αναγκάζει τους ερευνητές να καταφύγουν σε τεχνικές όπως η SMOTE (υπερδειγματοληψία) ή η τυχαία υποδειγματοληψία. Στη συγκεκριμένη περίπτωση όμως, η τέλεια ισορροπία των κλάσεων εξαλείφει την ανάγκη για τεχνικές εξισορρόπησης και διασφαλίζει ότι τα μοντέλα δεν θα αναπτύξουν προκατάληψη (bias) προς κάποια κλάση καθιστώντας το μετρικό Accuracy απόλυτα έγκυρο.

```
Κατανομή Κλάσεων:
sentiment
positive    25000
negative    25000
Name: count, dtype: int64
/tmp/ipykernel_5706/2546176989.py:6: FutureWarning:
Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.
sns.countplot(x='sentiment', data=df, palette='viridis')
```



3.2 Κατανομή Μήκους Κειμένων

Το ιστόγραμμα συχνοτήτων του μήκους των κριτικών (Review Length Distribution) που κατασκευάστηκε μετά την ολοκλήρωση του preprocessing παρουσιάζει μια ξεκάθαρη θετική ασυμμετρία (right-skewed / log-normal distribution).

Η πλειονότητα των χρηστών επιλέγει να εκφράσει την άποψή της σύντομα, με αποτέλεσμα η κορυφή της καμπύλης (mode) να εντοπίζεται μεταξύ 300 και 700 χαρακτήρων. Ωστόσο, η ύπαρξη μιας πολύ μακράς δεξιάς «ουράς» στο γράφημα, που εκτείνεται μέχρι τους 8.000 χαρακτήρες υποδεικνύει την ύπαρξη μιας μικρής ομάδας χρηστών που πραγματοποιούν εξαιρετικά εκτενείς και αναλυτικές, σχεδόν επαγγελματικές κριτικές κινηματογράφου, οι οποίες αγγίζουν ή και ξεπερνούν τους 4.000 χαρακτήρες.

σαφέστατες ελλείψεις, που δεν μπορούν να καλυφθούν, παρόλο που επιλέγεται λόγω της απλότητας και της ταχύτητας του.

2. Support Vector Machines (LinearSVC): Αποτελεί ισχυρό αλγόριθμο που στοχεύει στην εύρεση ενός υπερεπιπέδου (hyperplane) σε χώρο των 5.000 διαστάσεων (features). Κάθε κριτική αποτελεί κουκίδα στον χώρο που κατηγοριοποιείται με διαφορετικά χρώματα. Το μοντέλο προσπαθεί να σχεδιάσει μία ευθεία γραμμή που να χωρίζει τις 2 κατηγορίες μεταξύ τους, μεγιστοποιώντας την απόσταση από τα πιο κοντινά σημεία εκπαίδευσης (support vectors).

4.2 K-Means Clustering (Unsupervised Learning)

Σε αυτό το σημείο, εφαρμόσαμε τον αλγόριθμο K-Means με $K=2$ (2 στοίβες) πάνω στους πίνακες TF-IDF, με την αφαίρεση των ταμπελών positive/negative. Σκοπός μας με αυτή την διαδικασία ήταν να εξερευνηθεί αν η δομή των κειμένων επιτρέπει τον φυσικό διαχωρισμό τους. Η εξαγωγή των 10 κορυφαίων λέξεων ανά cluster έδωσε τα εξής αποτελέσματα:

- Cluster 0: movie, like, one, bad, good, really, time, would, see, even
- Cluster 1: film, one, like, movie, character, show, story, time, good, get

Από τα παραπάνω αποτελέσματα συμπεράναμε πως ο K-Means απέτυχε να διαχωρίσει τις κριτικές σε ξεκάθαρα θετικές ή αρνητικές, καθώς οι λέξεις like και good υπάρχουν και στα δύο clusters. Αντίθετα, πραγματοποίησε lexical/stylistic clustering. Το Cluster 0 αντιπροσωπεύει κριτικές που εστιάζουν κυρίως στην έντονη αξιολόγηση και έκφραση άποψης. Παρατηρούμε ότι το Cluster 1 περιλαμβάνει σχετικές μεταξύ τους λέξεις όπως character, show, story, plot, ομαδοποιώντας κριτικές που εστιάζουν στην αφήγηση και την περιγραφή της ταινίας. Άρα, παρατηρήθηκε ο clustering αλγόριθμος να τείνει περισσότερο στο θέμα παρά στο συναίσθημα.

```
Εκτέλεση KMeans Clustering
Top 10 Λέξεις ανά Cluster (Insights)
Cluster 0:
movie, like, one, bad, good, really, time, would, see, even
Cluster 1:
film, one, like, movie, character, show, story, time, good, get
```

5. Αξιολόγηση και Σύγκριση Μοντέλων

Η αξιολόγηση των δύο βασικών μοντέλων ταξινόμησης πραγματοποιήθηκε στο Test Set (10.000 δείγματα) και οδήγησε τα παρακάτω αποτελέσματα:

5.1 Πίνακας Συγκεντρωτικών Metrics


Naive Bayes Results				
	precision	recall	f1-score	support
0	0.85	0.84	0.85	4961
1	0.85	0.86	0.85	5039
accuracy			0.85	10000
macro avg	0.85	0.85	0.85	10000
weighted avg	0.85	0.85	0.85	10000

Όπως φαίνεται στα αποτελέσματα, ο probabilistic αλγόριθμος Naive Bayes σημείωσε ακρίβεια (accuracy) 85%. Για την αρνητική κλάση (0), πέτυχε precision 85% και recall 84%, ενώ για την θετική (1) precision 85% και recall 86%. Το f1-score είναι στο 85% και για τις δύο. Η γενική εικόνα των αποτελεσμάτων είναι θετική, αν και όχι η βέλτιστη, καθώς προσφέρει ικανοποιητικά ποσοστά επιτυχίας παρόλο που υστερεί στον τομέα της συνδεσιμότητας των λέξεων.

SVM Results				
	precision	recall	f1-score	support
0	0.89	0.87	0.88	4961
1	0.87	0.89	0.88	5039
accuracy			0.88	10000
macro avg	0.88	0.88	0.88	10000
weighted avg	0.88	0.88	0.88	10000

Ο αλγόριθμος Support Vector Machines πέτυχε ακρίβεια 88%, μεγαλύτερη από αυτή του Naive Bayes. Οι δύο precision είναι 89% και 87%, ενώ τα recall 87% και 89% (αντίστροφα για κάθε κλάση). Το f1-score φτάνει το 88% και για τις δύο κλάσεις, το οποίο δηλώνει πως η γεωμετρική προσέγγιση μεγιστοποίησης του margin διαχειρίζεται πιο αποτελεσματικά το σύνολο των 5000 χαρακτηριστικών.

5.2 Ανάλυση Μητρών Σύγχυσης (Confusion Matrices)




Το παραπάνω σχήμα αφορά την απόδοση τις μήτρες σύγχυσης και των δύο αλγορίθμων, που σημειώνει το μέγεθος των σφαλμάτων για τον κάθε έναν.

- Naive Bayes: Το μοντέλο βρήκε 4191 True Negatives (TN) και 4324 True Positives (TP). Ωστόσο, παρουσίασε 770 False Positives (αρνητικές που θεωρήθηκαν θετικές) και 715 False Negatives (θετικές που θεωρήθηκαν αρνητικές).
- Linear SVM: Το SVM παρουσιάζει σημαντική βελτίωση όσον αφορά τα σφάλματα, αυξάνοντας τα σωστά αποτελέσματα σε 4316 TN και 4480 TP και μειώνοντας τα σφάλματα στα 645 FP και 559 FN.

Με την εκτέλεση και την σύγκριση των αποτελεσμάτων των διαφορετικών μοντέλων, καταφέραμε να αποδείξουμε την υπεροχή του Linear Support Vector Machines, έναντι του απλού Naive Bayes.

5.3 Ανάλυση Καμπύλης ROC / AUC

Η καμπύλη ROC (Receiver Operating Characteristic) αποτυπώνει τη σχέση μεταξύ του True Positive Rate του False Positive Rate για κάθε πιθανό threshold ταξινόμησης.



Από το διάγραμμα του ROC, φαίνεται μία καθαρή κυριαρχία του SVM , καθώς η καμπύλη του (πράσινο χρώμα) βρίσκεται σταθερά πιο κοντά στην πάνω αριστερή γωνία του γραφήματος. Το AUC Score του δείχνει επιτυχία, αφού φτάνει το 0.95 έναντι του 0.93 του Naive Bayes. Η σημασία του AUC είναι ότι το SVM έχει 95% πιθανότητα να διακρίνει σωστά οποιαδήποτε θετική κριτική από μία αρνητική.

Παρακάτω φαίνονται σε πίνακα τα προαναφερθέντα αποτελέσματα (accuracy και AUC scores).

Τελική Σύγκριση		
Model	Accuracy	AUC Score
Naive Bayes	0.8515	0.929572
SVM	0.8796	0.953346
Analysis Complete!		

5.4 Αιτιολόγηση Ανωτερότητας του SVM

Η υπεροχή του Linear SVM έναντι του Naive Bayes στην εργασία, οφείλεται στην μαθηματική φύση των δύο αλγορίθμων.

Ο τρόπος που διαχειρίζεται τους πολυδιάστατους χώρους αποτελεί μεγάλο πλεονέκτημα. Η TF-IDF δημιούργησε έναν πίνακα 5000 χαρακτηριστικών, γεμάτο 0 (μηδενικά). Τα Support Vector Machines είναι μαθηματικά βελτιστοποιημένα να λειτουργούν σε τέτοιους χώρους, καθώς αναζητούν το μέγιστο περιθώριο διαχωρισμού, αποφεύγοντας το overfitting. Παράλληλα, ο Naive Bayes υποθέτει ότι όλες οι εμφανίσεις των λέξεων αποστασιοποιούνται εντελώς από τις υπόλοιπες, οδηγώντας πολλές φορές σε ασάφεια. Στην φυσική γλώσσα, οι λέξεις συχνά εμφανίζονται σε συνδυασμούς και στηρίζονται στα συμφραζόμενα και τις εκφράσεις. Το SVM δεν δεσμεύεται από αυτή την απλή υπόθεση και μπορεί να επεξεργαστεί πιο σύνθετες γραμμικές συσχετίσεις μεταξύ των τιμών TF-IDF.

6. Συμπεράσματα

Η ολοκληρωμένη ανάλυση του IMDB Dataset για την αναγνώριση συναισθήματος σε κριτικές ταινιών οδήγησε σε σημαντικά συμπεράσματα σε επίπεδο επιλογής σωστών αλγορίθμων.

Μπορούμε να σημειώσουμε την αδιαμφισβήτητη κρισιμότητα της προεπεξεργασίας του κειμένου μέσω καθαρισμού με αφαίρεση HTML tags, σημείων στίξης και συμβόλων που ενδέχεται να επέμβουν στα αποτελέσματα με αθέμιτο τρόπο. Με το lemmatization επιτυγχάνεται μείωση του θορύβου και διατήρηση της απόδοσης και της ακρίβειας σε υψηλά ποσοστά.

Επίσης σημαντική παρατήρηση είναι ότι η εποπτευόμενη μάθηση (Supervised Learning) είναι απαραίτητη για τον διαχωρισμό του συναισθήματος. Όπως συμπεράναμε παραπάνω, με τον k-means clustering χωρίς χρήση ετικετών, η κατηγοριοποίηση έγινε με βάση το γενικό θέμα της κριτικής και όχι το συναίσθημα (positive/negative) όπως θα ήταν το επιθυμητό αποτέλεσμα.

Κατά την σύγκριση των ταξινομητών, πιο αποτελεσματικός αναδείχθηκε το μοντέλο Linear SVM το οποίο κυριαρχούσε έναντι του Naive Bayes σημειώνοντας πολύ υψηλά ποσοστά Accuracy, Recall και AUC, ενώ σημείωσε περισσότερα True Negatives/True Positives και λιγότερα False Negatives/False Positives. Αποδείχθηκε πως για τέτοιου είδους πίνακες, υπερισχύει η γεωμετρική προσέγγιση μεγιστοποίησης του margin.